

PROPOSAL PENELITIAN

**Analisis Optimasi *Real-Time Pipeline* Nvidia DeepStream untuk Aplikasi ADAS
Berbasis Jetson AGX Orin**



**OLEH:
PERDI
D121221015**

**DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS HASANUDDIN
2026**

LEMBAR PENGESAHAN

Judul : Analisis Optimasi *Real-Time Pipeline* Nvidia DeepStream
untuk Aplikasi ADAS Berbasis Jetson AGX Orin
Nama : Perdi
NIM : D121221015
Departemen : Teknik Informatika

Diajukan sebagai salah satu syarat akademik pada Program Sarjana
Universitas Hasanuddin.

**Menyetujui,
Calon Pembimbing**

Dr. Muhammad Abdillah Rahmat, S.T., M.T.
NIP 199510262024123001

Form Revisi Proposal Hasil Seminar

Nama : Perdi
NIM : D121221015

Judul proposal pada saat seminar proposal :
Analisis Optimasi *Real-Time Pipeline* Nvidia DeepStream untuk Aplikasi ADAS
Berbasis Jetson AGX Orin

Komentar penolakan pada saat seminar proposal:

-

Judul proposal baru : ~~berubah~~ / tidak berubah

Judul proposal baru (jika berubah):

-

Menyetujui calon pembimbing:

1. Dr. Muhammad Abdillah Rahmat, S.T., M.T.

(Tanda Tangan)

Uraikan poin-poin perbaikan yang menunjukkan bahwa proposal yang diusulkan layak menjadi tugas akhir (kompleksitas, use case, ketersediaan data, dll) (1-2 halaman)

- Ditambahkan perangkat uji alternatif selain AGX Orin untuk memperoleh perbandingan kinerja. Apabila memungkinkan, implementasi dilakukan pada perangkat dengan spesifikasi yang lebih rendah dibandingkan perangkat yang dipilih.

I. Judul

Judul penelitian yang akan diangkat adalah “Analisis Optimasi *Real-Time Pipeline* Nvidia DeepStream untuk Aplikasi ADAS Berbasis Jetson AGX Orin”.

II. Latar Belakang

Perkembangan sistem bantuan pengemudi atau *advanced driver assistance systems* (ADAS) menunjukkan bahwa teknologi ini semakin diposisikan sebagai komponen penting dalam peningkatan keselamatan berkendara. Temuan terbaru menunjukkan bahwa penerapan ADAS berpotensi menurunkan angka kecelakaan berat serta mendukung agenda keselamatan jalan raya secara lebih luas, khususnya ketika fitur-fitur bantu berkendara mulai diadopsi secara lebih merata pada kendaraan modern (Costa et al., 2025). Sejalan dengan itu, kajian terhadap ADAS juga menunjukkan bahwa pengguna cenderung menilai sistem ini mampu meningkatkan rasa aman dan kenyamanan berkendara, meskipun masih dibutuhkan penyempurnaan berkelanjutan agar manfaatnya benar-benar optimal dalam konteks keselamatan (Neumann, 2024). Kondisi tersebut menegaskan bahwa kebutuhan akan sistem bantuan pengemudi yang andal bukan lagi sekadar pilihan teknologi, melainkan kebutuhan nyata dalam upaya menekan risiko kecelakaan di jalan.

Dalam konteks kendaraan cerdas, kemampuan sistem untuk memahami lingkungan secara cepat dan akurat menjadi prasyarat utama. ADAS sangat bergantung pada pemrosesan video dan citra secara terus-menerus agar kendaraan dapat mengenali objek penting, membaca situasi lalu lintas, serta merespons potensi bahaya secara tepat waktu. Studi terkini menekankan bahwa penguatan ADAS melalui *computer vision* dan pendekatan *machine learning* memang meningkatkan kapabilitas deteksi, tetapi sekaligus menuntut proses komputasi yang lebih besar dan lebih berkelanjutan (Shah et al., 2025). Pada saat yang sama, implementasi berbasis perangkat *embedded edge* untuk deteksi objek dan pembentukan informasi lingkungan menunjukkan bahwa pengolahan data visual secara *real-time* merupakan aspek mendasar dalam sistem kendaraan yang aman dan responsif (Choi et al., 2024). Oleh karena itu, *real-time processing* bukan hanya karakteristik teknis, melainkan inti dari keandalan sistem keselamatan pada kendaraan cerdas.

Persoalan utama muncul ketika kebutuhan pemrosesan *real-time* berhadapan dengan tuntutan latensi yang sangat rendah. Pada sistem berbasis *edge*, keterlambatan sekecil apa pun dapat mengurangi kualitas keputusan dan menurunkan efektivitas peringatan dini, terutama ketika beban inferensi berjalan secara dinamis di lingkungan jaringan yang

berubah-ubah. Kajian mengenai *inference serving* dengan *end-to-end latency SLOs* menunjukkan bahwa ketepatan waktu penyajian inferensi sama pentingnya dengan akurasi model, khususnya pada jaringan *edge* yang bersifat dinamis (Nigade et al., 2024). Di sisi lain, penelitian tentang penempatan server *edge* menegaskan bahwa pengaturan sumber daya yang tidak tepat dapat memperbesar latensi transmisi dan memperberat beban kerja sistem, sehingga mengganggu pencapaian kinerja waktu nyata yang dibutuhkan aplikasi kritis (Zhang et al., 2024). Dengan demikian, tantangan utama pada ADAS bukan hanya menghasilkan keluaran yang benar, tetapi juga memastikan keluaran tersebut hadir dalam batas waktu yang aman untuk pengambilan keputusan berkendara.

Tantangan tersebut menjadi semakin kompleks ketika sistem dijalankan pada perangkat *embedded* dengan sumber daya terbatas. Optimasi *deployment* pada platform *embedded heterogen* diperlukan agar kebutuhan *frame rate*, akurasi, dan efisiensi energi tetap terpenuhi (Ruiz-Barroso et al., 2025). Platform seperti Jetson AGX Orin menawarkan kemampuan komputasi yang tinggi untuk kelas perangkat *edge*, namun tetap berada dalam batasan konsumsi daya, suhu operasi, dan kapasitas pemrosesan yang tidak dapat disamakan dengan server kelas pusat. Kajian terhadap perangkat *embedded* menunjukkan bahwa pemrosesan video *real-time* selalu menuntut kompromi antara kecepatan, efisiensi energi, dan stabilitas kinerja, terutama ketika sistem harus mempertahankan hasil yang konsisten pada beban kerja yang berubah-ubah (Suder et al., 2023). Dalam konteks aplikasi keselamatan, kompromi semacam ini menjadi sangat penting karena keterbatasan sumber daya dapat langsung berpengaruh pada keterlambatan deteksi, penurunan laju pemrosesan, dan berkurangnya kemampuan sistem dalam mempertahankan performa secara berkelanjutan.

Selain beban komputasi, sistem ADAS juga menuntut karakteristik *deterministic* dan stabil karena bersifat *safety-critical*. Setiap proses harus selesai sesuai tenggat waktu agar fungsi peringatan, deteksi, dan respons dapat berjalan secara konsisten di bawah kondisi operasional yang berubah cepat. Studi terbaru menunjukkan bahwa penjadwalan tugas pada ADAS memiliki tingkat kepekaan yang tinggi terhadap deadline, dan kegagalan memenuhi batas waktu dapat berimplikasi pada kegagalan sistem secara fungsional (Seyfipoor et al., 2026). Hal ini menegaskan bahwa aplikasi keselamatan memerlukan arsitektur yang tidak hanya cepat, tetapi juga stabil, terprediksi, dan efisien dalam mengelola prioritas pemrosesan. Dengan kata lain, keandalan ADAS tidak dapat dilepaskan dari kemampuan sistem untuk menjaga konsistensi waktu proses dalam kondisi beban tinggi.

Berdasarkan uraian tersebut, terlihat bahwa penelitian mengenai optimasi *real-time pipeline* pada platform *embedded* menjadi relevan dan mendesak untuk dilakukan, khususnya pada konteks ADAS berbasis Jetson AGX Orin. Permasalahan yang dihadapi bukan semata-mata pada kemampuan mendeteksi objek, melainkan pada bagaimana sistem dapat mempertahankan kecepatan, kestabilan, dan efisiensi pemrosesan secara simultan dalam skenario operasi yang menuntut respons segera. Oleh karena itu, penelitian ini diarahkan untuk memahami dan menganalisis faktor-faktor yang memengaruhi kinerja *real-time pipeline* agar sistem ADAS dapat memenuhi kebutuhan keselamatan berkendara secara lebih andal.

III. Rumusan Masalah

Berdasarkan latar belakang penelitian, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana kinerja *real-time pipeline* Nvidia DeepStream pada proses deteksi kendaraan di Jetson AGX Orin?
2. Sejauh mana penerapan *custom CUDA logic* untuk parallel *Non-Maximum Suppression* (NMS) dapat meningkatkan efisiensi *pipeline* deteksi kendaraan dibandingkan konfigurasi standar?
3. Sejauh mana implementasi *heterogeneous computing* yang melibatkan DLA dapat mengoptimalkan efisiensi pemrosesan *pipeline* dibandingkan dengan pemrosesan yang berbasis pada *GPU baseline*?

IV. Tujuan Penelitian

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis kinerja *real-time pipeline* Nvidia DeepStream pada deteksi kendaraan di Jetson AGX Orin.
2. Mengevaluasi pengaruh optimasi *pipeline*, khususnya penerapan *custom CUDA logic* untuk parallel NMS, terhadap peningkatan performa pemrosesan *real-time*.
3. Mengevaluasi sejauh mana integrasi DLA dalam skema komputasi *heterogen* mampu mengoptimalkan performa *pipeline* dibandingkan dengan penggunaan sumber daya *GPU baseline*.

V. Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Manfaat Teoritis

Menjadi referensi ilmiah mengenai optimasi *pipeline* pemrosesan video *real-time* pada sistem *edge* untuk aplikasi ADAS, khususnya dalam penerapan Nvidia DeepStream, *custom CUDA logic* untuk parallel *Non-Maximum Suppression* (NMS), serta evaluasi penggunaan DLA pada perangkat Jetson AGX Orin.

2. Manfaat Praktis

Memberikan pedoman teknis bagi pengembang sistem embedded dan ADAS mengenai konfigurasi *pipeline* yang paling optimal untuk mencapai kinerja *real-time*, terutama dalam aspek latensi, *throughput*, dan stabilitas pemrosesan pada perangkat Jetson AGX Orin.

3. Manfaat Institusional

Berkontribusi dalam pengembangan riset terapan di bidang Visi Komputer, *Edge AI*, dan *Embedded Systems*, serta memperkuat kapasitas institusi dalam kajian pemanfaatan teknologi akselerasi perangkat keras NVIDIA pada sistem cerdas berbasis video.

VI. Batasan Penelitian

Agar penelitian lebih terarah dan fokus, maka batasan penelitian ini adalah sebagai berikut:


1. Pengujian penelitian dilakukan hanya pada perangkat Jetson AGX Orin sebagai platform utama eksperimen.
2. Peningkatan performa dianalisis hanya berdasarkan perbandingan *pipeline* sebelum dan sesudah optimasi menggunakan NVIDIA DLA dan *custom CUDA logic* untuk parallel NMS.
3. Penelitian menggunakan model *pre-trained* sehingga tidak berfokus pada proses pelatihan maupun peningkatan akurasi model deteksi.
4. Penelitian hanya membahas *pipeline* pemrosesan video dan tidak mencakup integrasi dengan sistem kendaraan secara keseluruhan.

VII. Penelitian Terkait

Judul	Penulis (Tahun)	Penerbit	Metodologi	Hasil Utama
Scalable Hardware Acceleration of Non-Maximum Suppression	Chunyun Chen, dkk. (2022)	EDAA (DATE Conference)	Memperkenalkan ShapoolNMS, sebuah akselerator perangkat keras yang skalabel untuk algoritma PSRR-MaxpoolNMS.	Mencapai percepatan 305x hingga 3626x dibandingkan perangkat lunak GreedyNMS dengan tetap menjaga akurasi deteksi yang sebanding.
Assessing YOLO models for real-time object detection in urban environments for ADAS	Riadh Ayachi, dkk. (2025)	Elsevier (Alexandria Engineering Journal)	Melakukan evaluasi komprehensif terhadap model YOLO v1 hingga v9 menggunakan <i>transfer learning</i> pada dataset BDD100K.	YOLO v9 memberikan keseimbangan optimal antara kecepatan (34 FPS) dan akurasi (85,54% mAP) untuk aplikasi ADAS secara <i>real-time</i> .
Real-Time Object Recognition for ADAS Using Deep Learning on Edge Devices	Santhosh Kumar Dhatrika, dkk. (2025)	Elsevier (Procedia Computer Science)	Mengimplementasikan YOLOv9 pada NVIDIA Jetson Nano menggunakan optimasi TensorRT dan kerangka kerja DeepStream.	Mencapai mAP tinggi sebesar 91,9%, secara signifikan mengungguli model lama seperti YOLOv5 dan YOLOv8 dalam deteksi objek <i>real-time</i> .
Road Object Detection using SSD-MobileNet Algorithm: Case Study for Real-Time ADAS Applications	Omar Bouazizi, dkk. (2024)	Universitas Muhammadiyah Yogyakarta (JRC)	Melatih kembali model SSD-MobileNet yang ringan menggunakan <i>transfer learning</i> pada subset dataset MS COCO khusus objek jalan raya.	Mencapai mAP 65,41% pada 71 FPS, memprioritaskan <i>recall</i> tinggi (0,873) untuk memastikan keselamatan pada deteksi pejalan kaki.
Work-Efficient Parallel Non-Maximum Suppression Kernels	David Oro, dkk. (2020)	Oxford University Press (The Computer Journal)	Mengembangkan kernel CUDA yang sangat skalabel menggunakan matriks adjasensi boolean untuk menyelesaikan masalah NMS secara paralel pada GPU tertanam.	Mampu mengelompokkan 1024 objek dalam waktu sekitar 1 ms pada GPU Tegra X1/X2, mencapai percepatan 14x-40x dibandingkan metode NMS berbasis CNN yang ada.


A Real-Time Vehicle Detection System for ADAS Using YOLOv11 on Embedded Edge Platforms	Mohammed Chaman, dkk. (2025)	ETASR	Menerapkan model YOLOv11 pada Jetson Nano dan Raspberry Pi 5 menggunakan dataset kustom berisi 38.500 gambar.	Mencapai mAP@50 sebesar 98,1%; membuktikan bahwa YOLOv11 cukup tangguh untuk mendeteksi kendaraan modern seperti <i>e-scooters</i> .
Quantized Object Detection for Real-Time Inference on Embedded GPU Architectures	Fatima Zahra Guerrouj, dkk. (2025)	SAI Organization (IJACSA)	Menguji teknik kuantisasi post-training INT8 pada YOLOv4 untuk mengurangi ukuran model dan kompleksitas pada perangkat <i>edge</i> .	Kuantisasi memungkinkan Jetson Nano mencapai kecepatan 5 FPS (naik dari <2 FPS) dengan kehilangan akurasi minimal, membuat YOLOv4 lebih layak untuk <i>edge AI</i> .
Real-Time Object Detection from UAV Inspection Videos by Combining YOLOv5s and DeepStream	Shidun Xie, dkk. (2024)	MDPI (Sensors)	Menggabungkan YOLOv5s dengan DeepStream SDK untuk mengotomatisasi deteksi objek dari video inspeksi UAV pada ketinggian tinggi.	Berhasil mengaktifkan deteksi kendaraan <i>real-time</i> dengan mAP50 sebesar 93,2%, membuktikan efektivitas <i>pipeline</i> DeepStream untuk aplikasi UAV.
Object Detection Post Processing Accelerator Based on Co-Design of Hardware and Software	Dengtian Yang, dkk. (2025)	MDPI (Information)	Mengusulkan akselerator perangkat keras untuk <i>post-processing</i> menggunakan prioritas klasifikasi untuk mengurangi kalkulasi IoU yang redundan.	Mencapai percepatan 19,89x pada tahap inferensi dan percepatan 7,55x pada tugas NMS dibandingkan dengan sistem GPU tradisional (RTX 2080 Ti).
Analysis of Advanced Driver-Assistance Systems for Safe and Comfortable Driving of Motor Vehicles	Tomasz Neumann (2024)	MDPI (Sensors)	Menganalisis operasional berbagai sensor ADAS dan melakukan studi survei terhadap 80 pengemudi untuk mengevaluasi tingkat kepercayaan mereka.	Lebih dari 50% pengemudi merasa jauh lebih aman dengan ADAS; namun, hasil survei menekankan perlunya peningkatan presisi untuk mengurangi alarm palsu.

VIII. Langkah Penelitian



Gambar 1. Usulan Sistem

1. Konfigurasi Sistem dan Model




Gambar 2. Setup dan Konfigurasi Edge Device

Tahap awal penelitian dilakukan melalui penyiapan lingkungan komputasi pada Jetson AGX Orin dengan instalasi NVIDIA JetPack SDK menggunakan NVIDIA SDK Manager. JetPack merupakan paket pengembangan terpadu untuk aplikasi AI pada platform Jetson yang menyediakan Jetson Linux beserta pustaka akselerasi seperti CUDA, cuDNN, dan TensorRT, sedangkan DeepStream SDK digunakan sebagai kerangka pemrosesan video streaming untuk membangun *pipeline* inferensi berbasis akselerasi perangkat keras.

Model deteksi objek yang digunakan sebagai *baseline* adalah YOLOv8n, karena varian ini dirancang untuk mendukung inferensi *real-time* dengan kompleksitas model yang rendah sehingga sesuai untuk skenario *edge computing* yang menuntut latensi kecil dan efisiensi sumber daya. Tsai et al. (2025) melaporkan bahwa YOLOv8n pada sistem *collision warning* berbasis ADAS mampu mencapai 176,8 FPS dengan ukuran model 4,5 MB, meskipun nilai mAP-nya sedikit lebih rendah dibandingkan varian yang lebih besar; hasil ini menunjukkan kompromi yang kuat antara kecepatan dan akurasi untuk aplikasi real-time. Sejalan dengan itu, Wu et al. (2024) menempatkan YOLOv8 sebagai basis pengembangan deteksi objek pada road scene, yang menguatkan kelayakan YOLOv8n sebagai model awal untuk eksperimen deteksi kendaraan pada lingkungan berkendara.

2. Optimalisasi Pipeline untuk Edge Device




Gambar 3. Pipeline

Tahap kedua penelitian difokuskan pada perbandingan dua skenario eksekusi *pipeline*, yaitu GPU *baseline* dan komputasi *heterogen*. Pada skenario *baseline*, *Gst-nvinfer* digunakan untuk menjalankan inferensi TensorRT pada GPU, sedangkan pada skenario *heterogen*, inferensi dikonfigurasi untuk memanfaatkan DLA pada Jetson AGX Orin melalui opsi `enable-dla`, yang memang didukung pada platform Jetson AGX Orin dan Jetson Orin NX. Dengan konfigurasi ini, beban inferensi dapat dialihkan ke DLA, sementara GPU tetap digunakan untuk menangani tahapan pemrosesan lanjutan dalam *pipeline*.

Untuk memisahkan beban inferensi dan pascaproses secara lebih terstruktur, tahap *Non-Maximum Suppression* (NMS) ditempatkan pada komponen *post-processing* kustom, yaitu *gst-nvdsppostprocess*, yang dirancang untuk memproses tensor keluaran dari *nvinfer* atau *nvinferserver*. Pada tahap ini, NMS diimplementasikan sebagai custom CUDA kernel agar penyaringan bounding box dilakukan secara paralel di GPU dan tidak menjadi *bottleneck* setelah inferensi selesai. Pendekatan tersebut sejalan dengan literatur yang menunjukkan bahwa tahap NMS pada *post-processing* masih menjadi *bottleneck* dan dapat dipercepat secara signifikan (Yang et al., 2025).

3. Deployment




Gambar 4. Deployment Pipeline

Tahap *deployment* dalam penelitian ini merupakan proses integrasi menyeluruh dari seluruh hasil konfigurasi yang telah dilakukan pada tahap sebelumnya ke dalam satu sistem yang utuh dan siap dijalankan pada perangkat Jetson AGX Orin. Pada tahap ini,

komponen *pipeline* yang telah disusun, mulai dari input video, pemrosesan, inferensi model, hingga *post-processing*, digabungkan dan disesuaikan agar dapat berjalan secara terpadu dalam lingkungan operasional yang stabil. Selain itu, sistem juga diintegrasikan dengan perangkat dashcam sebagai sumber input video sehingga *pipeline* tidak lagi berada pada tahap konfigurasi terpisah, melainkan telah menjadi satu kesatuan fungsional yang merepresentasikan skenario penggunaan nyata. Dengan demikian, *deployment* berperan sebagai tahap finalisasi implementasi, yaitu memastikan seluruh komponen siap digunakan secara operasional sebelum memasuki tahap berikutnya, yakni uji performa sistem secara terukur.


4. Uji Performa



Gambar 5. Testing Performa

Tahap uji performa dalam penelitian ini dilakukan untuk mengevaluasi kinerja sistem setelah *pipeline* diimplementasikan secara utuh pada Jetson AGX Orin dalam kondisi operasional yang mendekati penggunaan nyata. Pengujian memanfaatkan dashcam sebagai sumber input video dengan orientasi kamera menghadap ke depan searah kendaraan, sehingga sistem diuji dalam mendeteksi objek diam maupun objek bergerak di lingkungan lalu lintas. Selama proses pengujian, digunakan NVIDIA Nsight Systems untuk melakukan *profiling* terhadap eksekusi pipeline secara rinci, khususnya dalam menganalisis durasi eksekusi kernel, alur komputasi CPU–GPU, serta potensi *bottleneck* pada proses paralel. Selain itu, *tegrastats* dimanfaatkan untuk memantau penggunaan sumber daya perangkat secara langsung, seperti utilisasi CPU, GPU, memori, dan konsumsi daya, sehingga memberikan gambaran menyeluruh mengenai karakteristik performa sistem pada perangkat *edge*.

5. Analisis dan Benchmarking



Gambar 6. Proses Analisis dan Benchmarking

Tahap ini dilakukan untuk mengolah hasil pengukuran yang diperoleh selama proses pengujian agar dapat disajikan secara sistematis dan mudah dianalisis. Data yang berasal dari log monitoring terlebih dahulu melalui proses data *cleaning* untuk menghilangkan data yang tidak relevan, duplikat, atau tidak konsisten, kemudian dilanjutkan dengan agregasi data guna merangkum hasil berdasarkan skenario atau kondisi pengujian tertentu. Hasil yang telah diringkas kemudian disusun dalam bentuk tabel sehingga memudahkan proses perbandingan, dan selanjutnya divisualisasikan dalam bentuk grafik untuk menampilkan pola performa sistem secara lebih jelas. Proses ini bertujuan untuk mentransformasikan data mentah menjadi informasi yang terstruktur dan siap digunakan dalam analisis.

Metrik evaluasi yang digunakan dalam penelitian ini mencakup aspek performa sistem dan kualitas deteksi. Dari sisi performa, digunakan *end-to-end latency* untuk mengukur waktu respons sistem secara keseluruhan, serta *throughput* atau FPS untuk menilai kemampuan sistem dalam memproses frame secara berkelanjutan. Selain itu, dilakukan pengamatan terhadap utilisasi sumber daya seperti GPU, CPU, dan DLA, serta konsumsi daya untuk mengevaluasi efisiensi komputasi pada perangkat *edge*. Dari sisi kualitas deteksi, digunakan metrik *precision*, *recall*, dan *mean Average Precision (mAP)* untuk mengukur tingkat akurasi sistem dalam mendeteksi objek, sehingga memberikan gambaran menyeluruh antara kinerja komputasi dan keandalan hasil deteksi.

Daftar Pustaka

- Ayachi, R., Said, Y., Afif, M., Alshammari, A., Hleili, M., & Abdelali, A. B. (2025). Assessing YOLO models for real-time object detection in urban environments for advanced driver-assistance systems (ADAS). *Alexandria Engineering Journal*, 123, 530–549.
- Bouazizi, O., Azroumahli, C., El Mourabit, A., & Oussouaddi, M. (2024). Road object detection using SSD-MobileNet algorithm: Case study for real-time ADAS applications. *Journal of Robotics and Control*, 5(2), 551–562. <https://doi.org/10.18196/jrc.v5i2.21145>
- Chaman, M., dkk. (2025). A real-time vehicle detection system for ADAS using YOLOv11 on embedded edge platforms. *Engineering, Technology & Applied Science Research*.
- Chen, C., Zhang, T., Yu, Z., Raghuraman, A., Udayan, S., Lin, J., & Sabry Aly, M. M. (2022). Scalable hardware acceleration of non-maximum suppression. *Proceedings of the 2022 Design, Automation & Test in Europe Conference & Exhibition*, 96–99. <https://doi.org/10.23919/DATE54114.2022.9774717>
- Choi, K., Moon, J., Jung, H. G., & Suhr, J. K. (2024). Real-time object detection and tracking based on embedded edge devices for local dynamic map generation. *Electronics*, 13(5), 811. <https://doi.org/10.3390/electronics13050811>
- Costa, A., Innamaa, S., & Malin, F. (2025). Safety impact of advanced driver assistance systems in Europe in 2030. *Journal of Safety Research*, 95, 290–300. <https://doi.org/10.1016/j.jsr.2025.10.008>
- Dhatrika, S. K., dkk. (2025). Real-time object recognition for ADAS using deep learning on edge devices. *Procedia Computer Science*.
- Guerrouj, F. Z., Florez, S. R., El Ouardi, A., Abouzahir, M., & Ramzi, M. (2025). Quantized object detection for real-time inference on embedded GPU architectures. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 16(5), 415–424. <https://doi.org/10.14569/IJACSA.2025.0160503>
- Neumann, T. (2024). Analysis of advanced driver-assistance systems for safe and comfortable driving of motor vehicles. *Sensors*, 24(19), 6223. <https://doi.org/10.3390/s24196223>
- Nigade, V., Bauszat, P., Bal, H., & Wang, L. (2024). Inference serving with end-to-end latency SLOs over dynamic edge networks. *Real-Time Systems*, 60, 239–290. <https://doi.org/10.1007/s11241-024-09418-4>
- Oro García, D., Fernandez Tena, C., Martorell Bofill, X., & Hernando Pericás, F. J. (2020). Work-efficient parallel non-maximum suppression kernels. *The Computer Journal*, 63(12), 1–15. <https://doi.org/10.1093/comjnl/bxaa108>
- Ruiz-Barroso, P., Castro, F. M., & Guil, N. (2025). Real-time unsupervised video

- object detection on the edge. *Future Generation Computer Systems*, 167, 107737. <https://doi.org/10.1016/j.future.2025.107737>
- Seyfipoor, M., Jaffry, S. M., & Mohammadi, S. (2026). Adaptive urgency-based real-time task scheduling in ADAS systems. *Science of Computer Programming*, 251, 103436. <https://doi.org/10.1016/j.scico.2026.103436>
- Shah, H., Shah, K., Darji, K., Shah, A., & Shah, M. (2025). Advanced driver assistance system (ADAS) and machine learning (ML): The dynamic duo revolutionizing the automotive industry. *Virtual Reality & Intelligent Hardware*, 7(3), 203–236. <https://doi.org/10.1016/j.vrih.2025.01.002>
- Suder, J., Podbucki, K., & Marciniak, T. (2023). Power requirements evaluation of embedded devices for real-time video line detection. *Energies*, 16(18), 6677. <https://doi.org/10.3390/en16186677>
- Tsai, C.-Y., Hsu, C.-C., & Lin, Y.-C. (2025). Real-time collision warning system based on YOLOv8 for advanced driver assistance systems. *Electronics*, 14 (21), 4275. <https://doi.org/10.3390/electronics14214275>
- Wu, J., Zhang, Y., & Liu, H. (2024). Road object detection based on improved YOLOv8 for real-time traffic scenarios. *Sensors*, 24(3), 1023. <https://doi.org/10.3390/s24031023>
- Xie, S., dkk. (2024). Real-time object detection from UAV inspection videos by combining YOLOv5s and DeepStream. *Sensors*.
- Yang, D., Chen, L., Hao, X., & Zhang, Y. (2025). Object detection post processing accelerator based on co-design of hardware and software. *Information*, 16(1), 63. <https://doi.org/10.3390/info16010063>
- Zhang, S., Yu, J., & Hu, M. (2024). An edge server placement based on graph clustering in mobile edge computing. *Scientific Reports*, 14, 29986. <https://doi.org/10.1038/s41598-024-81684-5>